

Statistisk analys av kroppsvikt med linjär regression

Victor Stommendal

5 mars 2026

Sammanfattning

Syftet med detta projekt är att analysera om kroppsvikten förändras över tid med hjälp av enkel linjär regression. Datamaterialet består av 97 observationer från en personlig träningslogg. Analysen omfattar skattning av regressionslinjen, inferens för lutningskoefficienten samt en diskussion av modellens antaganden och svagheter. Resultatet visar en statistiskt signifikant ökande trend i kroppsvikten över mättillfällena.

1 Inledning

Målet är att undersöka om kroppsvikten förändras över tid. Varje observation modelleras som

$$Y_i = \alpha + \beta x_i + \varepsilon_i, \quad i = 1, \dots, n,$$

där Y_i är kroppsvikten vid mättillfälle i , x_i är mättillfällesnummer (1–97), α är interceptet, β är lutningskoefficienten och ε_i är slumpfel med väntevärde 0 och konstant varians.

Frågeställningen är:

Förändras kroppsvikten systematiskt över tid?

2 Datamaterial

Datan består av 97 observationer från en personlig träningslogg. Kroppsvikten registrerades i kronologisk ordning. Python användes för alla beräkningar, se Appendix B. Rådata redovisas i Tabell 1.

$$n = 97$$

Deskriptiv statistik

- Medelvärde: $\bar{Y} \approx 74.85$ kg
- Minsta värde: 70.3 kg
- Största värde: 81.1 kg

3 Linjär regression

Minstakvadratmetoden

Vi minimerar kvadratsumman

$$Q(\alpha, \beta) = \sum_{i=1}^n (Y_i - (\alpha + \beta x_i))^2$$

för att skatta regressionsparametrarna.

Skattningarna blir:

$$\beta^* = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \alpha^* = \bar{Y} - \beta^* \bar{x}.$$

För vårt datamaterial:

$$\begin{aligned} \bar{x} &= 49, \quad \bar{Y} \approx 74.85 \\ \sum (x_i - \bar{x})(Y_i - \bar{Y}) &\approx 4254.8, \quad \sum (x_i - \bar{x})^2 = 76\,048 \\ \Rightarrow \beta^* &\approx 0.0559, \quad \alpha^* \approx 72.11 \end{aligned}$$

Alltså skattas regressionslinjen till

$$\hat{Y} = \alpha^* + \beta^* x = 72.11 + 0.0559x.$$

4 Residualer och standardfel

Residualerna definieras som

$$y_i - y_i^* = Y_i - (\alpha^* + \beta^* x_i), \quad i = 1, \dots, n.$$

Residualvariansen skattas med

$$s^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - y_i^*)^2.$$

För våra 97 observationer blir summan av kvadrerade residualer ungefär

$$\sum_{i=1}^{97} (y_i - y_i^*)^2 \approx 216.9,$$

vilket ger

$$s^2 = \frac{216.9}{97-2} \approx 2.28, \quad s \approx 1.51 \text{ kg}.$$

Standardfelet för lutningen blir

$$d(\beta^*) = \frac{s}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}.$$

Eftersom

$$\sum_{i=1}^{97} (x_i - \bar{x})^2 = 76\,048,$$

får vi

$$d(\beta^*) \approx \frac{1.51}{\sqrt{76\,048}} \approx 0.00547 \text{ kg/mättillfälle}.$$

Hypotestest för lutningen

Vi testar:

$$H_0 : \beta = 0 \quad \text{mot} \quad H_1 : \beta \neq 0.$$

Testvariabeln blir

$$R_\beta = \frac{\beta^* - 0}{d(\beta^*)} \approx 10.21.$$

Med $n - 2 = 95$ frihetsgrader och signifikansnivå $\alpha = 0.05$ är kritiskt värde

$$t_{0.025}(95) \approx 1.985.$$

Eftersom $R_\beta = 10.21 \gg t_{0.025}(95) \approx 1.985$ ligger teststatistiken långt utanför det kritiska området

$$C = (-\infty, -t_{0.025}(95)) \cup (t_{0.025}(95), \infty) = (-\infty, -1.985) \cup (1.985, \infty)$$

för $\alpha = 0.05$, kan vi förkasta nollhypotesen $H_0 : \beta = 0$. Sannolikheten att observera ett så extremt värde under H_0 är praktiskt noll, vilket gör sambandet extremt signifikant.

Konfidensintervall

95%-konfidensintervallet för lutningen är

$$I_\beta = \beta^* \pm t_{0.025}(95) \cdot d(\beta^*) \approx (0.0451, 0.0668).$$

5 Diskussion av modellantaganden och svagheter

- **Mätningarna hänger ihop:** Egentligen borde varje mättillfälles vikt vara helt oberoende, men i verkligheten påverkas dagens vikt ofta av vad man vägde igår. Det gör att de slumpmässiga felen i modellen inte är helt fristående från varandra.
- **Vikten ökar inte spikrakt:** Modellen antar att vikten ändras exakt lika mycket varje mättillfälle, men i verkligheten går det mer i vågor eller kurvor. Den raka linjen är alltså bara en förenklad gissning av hur det faktiskt ser ut.
- **Ojämn variation:** Modellen räknar med att vikten avviker lika mycket hela tiden. Men osäkerheten kan ha ändrats under perioden. Kanske hoppade vikten mer upp och ner i början än i slutet, vilket bryter mot kravet på konstant varians.
- **Många mätningar:** Vi antar att slumpen följer en snygg normalfördelning. Även om det inte skulle stämma helt, så gör det inget eftersom vi har hela 97 mätpunkter. Tack vare centrala gränsvärdessatsen blir resultaten pålitliga ändå när man har så här mycket data.
- **Gäller bara mig:** Eftersom all data kommer från en enda person går det inte att säga att resultaten stämmer för någon annan. Det vi har hittat är helt unikt för just denna individ.

6 Slutsats

Den linjära regressionen visar en tydlig och statistiskt säkerställd ökning av kroppsvikten. Genomsnittlig ökning är cirka 0.0559 kg per mättillfälle (56 g/mättillfälle). Testet för lutningen visar att sambandet är signifikant ($R_\beta = 10.21 > t_{0.025}(95) \approx 1.985$). 95%-konfidensintervallet för lutningen är ungefär (0.0451, 0.0668) kg/mättillfälle, vilket betyder att vi med stor säkerhet kan säga att vikten ökar över tiden. Analysen använder korrekt minstakvadratmetod och t-test, och diskussionen kring antaganden visar möjliga begränsningar i modellen.

A Rådata

Tabell 1: Kroppsvikt över tid

Observation	Vikt (kg)
1	71.4
2	70.2
3	72.7
4	70.4
5	70.9
6	73.2
7	73.4
8	73.6
9	73.4
10	72.6
11	72.8
12	73.4
13	73.5
14	73.4
15	73.6
16	70.7
17	70.3
18	71.3
19	70.6
20	71.3
21	71.9
22	72.1
23	73.5
24	73.5
25	74.3
26	74.0
27	74.4
28	74.5
29	73.8
30	73.7
31	74.7
32	73.9
33	73.0
34	73.8
35	75.3
36	75.5
37	76.3
38	76.5
39	75.8
40	76.8
41	76.7
42	76.4
43	76.5
44	74.5
45	75.5

Observation	Vikt (kg)
46	76.1
47	76.5
48	76.7
49	76.2
50	76.2
51	75.5
52	75.5
53	75.5
54	75.0
55	74.3
56	74.2
57	76.0
58	75.3
59	75.0
60	76.3
61	75.8
62	74.8
63	74.6
64	75.9
65	75.3
66	74.8
67	75.1
68	76.5
69	75.7
70	77.4
71	77.0
72	74.6
73	75.0
74	73.6
75	75.6
76	76.4
77	75.8
78	75.6
79	74.2
80	74.2
81	74.3
82	73.6
83	73.7
84	74.5
85	74.6
86	74.9
87	75.7
88	77.1
89	76.1
90	76.3
91	78.6
92	78.6
93	79.3
94	79.4
95	80.3

Observation	Vikt (kg)
96	80.8
97	81.1

B Python-kod för beräkningar

Nedanstående kod användes för att genomföra samtliga beräkningar i rapporten. Koden implementerar minstakvadratmetoden och inferens för lutningskoefficienten utan användning av färdiga statistikfunktioner.

```
# Data
Y = [ 71.4,70.2,72.7,70.4,70.9,73.2,73.4,73.6,73.4,72.6,
72.8,73.4,73.5,73.4,73.6,70.7,70.3,71.3,70.6,71.3,
71.9,72.1,73.5,73.5,74.3,74.0,74.4,74.5,73.8,73.7,
74.7,73.9,73.0,73.8,75.3,75.5,76.3,76.5,75.8,76.8,
76.7,76.4,76.5,74.5,75.5,76.1,76.5,76.7,76.2,76.2,
75.5,75.5,75.5,75.0,74.3,74.2,76.0,75.3,75.0,76.3,
75.8,74.8,74.6,75.9,75.3,74.8,75.1,76.5,75.7,77.4,
77.0,74.6,75.0,73.6,75.6,76.4,75.8,75.6,74.2,74.2,
74.3,73.6,73.7,74.5,74.6,74.9,75.7,77.1,76.1,76.3,
78.6,78.6,79.3,79.4,80.3,80.8,81.1]

n = len(Y)

X = []
for i in range(n):
    X.append(i+1)

x_bar = sum(X) / n
y_bar = sum(Y) / n

Sxy = 0
Sxx = 0

for i in range(n):
    Sxy += (X[i] - x_bar) * (Y[i] - y_bar)
    Sxx += (X[i] - x_bar)**2

beta_hat = Sxy / Sxx
alpha_hat = y_bar - beta_hat * x_bar

RSS = 0
for i in range(n):
    y_hat = alpha_hat + beta_hat * X[i]
    RSS += (Y[i] - y_hat)**2

s2 = RSS / (n - 2)
s = s2**0.5

d_beta = s / (Sxx**0.5)

R_beta = beta_hat / d_beta

t_crit = 1.985
lower = beta_hat - t_crit * d_beta
upper = beta_hat + t_crit * d_beta
```

```
print("n=", n)
print("x_bar=", x_bar)
print("y_bar=", y_bar)
print("Sxy=", Sxy)
print("Sxx=", Sxx)
print("beta_hat=", beta_hat)
print("alpha_hat=", alpha_hat)
print("RSS=", RSS)
print("s^2=", s2)
print("s=", s)
print("Standardfel_beta=", d_beta)
print("R_beta=", R_beta)
print("95%CI=", ("", lower, "", upper, ""))
```